

Projet : Analyse de données

Spécialité : Génie Informatique

Elaboré par :

Ghazi OUMARI

Abed el Aziz BOUABSA

**ANALYSE DE BASE DE DONNÉES DES
CARACTÉRISTIQUES DES ORDINATEURS**

Réalisé au sein de

Ecole Nationale d'ingénieurs de Carthage

Encadré par Mme :

BEN NASR Feriel // KAMOUN Imen



Année universitaire
2023 - 2024

I) INTRODUCTION

Ce projet d'analyse de données se concentre sur l'étude d'une datasheet concernant les caractéristiques des ordinateurs, avec des variables telles que la RAM, la ROM et le poids.

Nous explorerons 500 individus et au moins 7 variables quantitatives , et 2 variables

qualitatives en évitant les données manquantes. L'analyse débutera par une exploration préalable des données, suivie de l'application de techniques avancées telles que l'ACP pour comprendre la structure de corrélation des variables. Ensuite, nous utiliserons la CAH et la méthode k-means pour classer les données et identifier des tendances de regroupement. Ce projet nous permettra de tirer des connaissances significatifs sur les caractéristiques des ordinateurs, pouvant être utiles dans divers domaines, de la conception de produits à la stratégie commerciale.

II) TABLE DE DONNÉES :

laptop_ID	Company	Inches	ScreenRes	Cpu	Ram	Memory	Weight	Price_euros
1	Apple	13,3	IPS Panel F	Intel Core	8GB	128GB SSC	1.37kg	1339,69
2	Apple	13,3	1440x900	Intel Core	8GB	128GB Fla	1.34kg	898,94
3	HP	15,6	Full HD 19	Intel Core	8GB	256GB SSC	1.86kg	575
4	Apple	15,4	IPS Panel F	Intel Core	16GB	512GB SSC	1.83kg	2537,45
5	Apple	13,3	IPS Panel F	Intel Core	8GB	256GB SSC	1.37kg	1803,6
6	Acer	15,6	1366x768	AMD A9-S	4GB	500GB HD	2.1kg	400
7	Apple	15,4	IPS Panel F	Intel Core	16GB	256GB Fla	2.04kg	2139,97
8	Apple	13,3	1440x900	Intel Core	8GB	256GB Fla	1.34kg	1158,7
9	Asus	14	Full HD 19	Intel Core	16GB	512GB SSC	1.3kg	1495
10	Acer	14	IPS Panel F	Intel Core	8GB	256GB SSC	1.6kg	770

Pour mieux se familiariser avec cette base de données, nous allons effectuer des transformations sur nos variables afin de les rendre plus compatibles avec notre étude :

*Pour les variables "Ram" et "Weight", nous allons simplement éliminer les unités (GB, Kg).

*Pour la variable "screenResolution", nous allons nous limiter au nombre de pixels sur l'écran.
Par exemple : Full HD 1920x1080 → $1920 \times 1080 = 2\,073\,600$ pixels.

*Pour la variable "Memory", nous allons la diviser en deux variables : une quantitative, "Memory_size", et une qualitative, "Memory_type".

Par exemple : 128GB SSD → Memory_size : 128 et Memory_type : SSD.

*Pour la variable "CPU", nous allons nous limiter à la fréquence du processeur et sa génération, et non pas à leur nom. Par exemple : Intel Core i5 7200U 2.5GHz → $2.3 * 7200 * 5$

***Les transformation :**

```

pattern = r'(\d+)x(\d+)'
df['Height'] = df['ScreenResolution'].str.extract(pattern)[0].astype(int)
df['Length'] = df['ScreenResolution'].str.extract(pattern)[1].astype(int)
df['ScreenResolution_Product'] = df['Height'] * df['Length']
del df["Length"]
del df["Height"]
# Dropping the original ScreenResolution column
df.drop(columns=['ScreenResolution'], inplace=True)
df['powerCpu'] = df['Cpu'].str.split(' ').str[-1].str.replace('GHz', '')
df['powerCpu'] = df['powerCpu'].astype(float)
df['Model'] = df['Cpu'].str.split(' ').str[2].str.replace('i', '')
df['Model'] = df['Model'].astype(float)
df['powerCpu'] = df['powerCpu']*df['Model']
df['Cpu_Generation'] = df['Cpu'].str.extract(r'Intel Core i\d+ (\d+)',
expand=False).fillna(4)
df['Cpu_Generation'] = df['Cpu_Generation'].astype(int)
df.loc[df['Cpu_Generation'] < 1000, 'Cpu_Generation'] = 7250
df['powerCpu'] = df['powerCpu']*df['Model']*df['Cpu_Generation']
del df["Model"]
del df["Cpu"]
del df["Cpu_Generation"]

df['Ram'] = df['Ram'].str.replace('GB', '')
df['Ram'] = df['Ram'].astype(int)
df['Weight'] = df['Weight'].str.replace('kg', '')
df['Weight'] = df['Weight'].astype(float)

df['Memory_size'] = df['Memory'].str.extract(r'(\d+)').astype(int)
df.loc[df['Memory'].str.contains('TB'), 'Memory_size'] *= 1024
df['Memory_Type'] = df['Memory'].str.split(' ').str[1]
df.loc[df['Memory_Type'] == 'HDD', 'Memory_size'] *= 1
df.loc[df['Memory_Type'] == 'SSD', 'Memory_size'] *= 1
del df["Memory"]

df.rename(columns={'ScreenResolution_Product': 'ScreenResolution'}, inplace=True)
# Extracting only numbers from Weight column
print(df)

```

TABLE DE DONNÉES FINAL :

	Company	Inches	Ram	Weight	Price_euros	ScreenResolution	\
laptop_ID							
1	Apple	13.3	8	1.37	1339.69	4096000	
3	HP	15.6	8	1.86	575.00	2073600	
4	Apple	15.4	16	1.83	2537.45	5184000	
5	Apple	13.3	8	1.37	1803.60	4096000	
9	Asus	14.0	16	1.30	1495.00	2073600	
...	...	...	...	...	...	...	
743	Lenovo	15.6	4	1.85	779.00	2073600	
744	HP	15.6	16	2.60	2419.00	2073600	
745	Dell	13.3	8	1.55	659.00	2073600	
747	Acer	15.6	4	2.40	410.80	1049088	
749	Dell	15.6	8	2.00	665.00	1049088	
	powerCpu	Memory_size	Memory_Type				
laptop_ID							
1	416875.0	128	SSD				
3	450000.0	256	SSD				
4	959175.0	512	SSD				
5	561875.0	256	SSD				
9	754110.0	512	SSD				
...	...	...	...				
743	992250.0	1024	HDD				
744	1056440.0	256	SSD				
745	330000.0	1024	HDD				
747	108108.0	500	HDD				
749	108108.0	256	SSD				


[500 rows x 9 columns]

III)Exploration préalable des données :


deux histogrammes, l'un pour la variable 'Price_euros' et l'autre pour la variable 'Weight' à

partir du DataFrame df.

```
array([[<Axes: title={'center': 'Weight'}>]], dtype=object)
```



- **Concentration des Prix** : La majorité des articles coûtent **moins de 1000 euros**, ce qui est indiqué par la barre la plus haute de l'histogramme.
- **Diminution avec le Prix** : Le nombre d'articles diminue considérablement à mesure que le prix augmente, avec très peu d'articles dans la gamme de prix de **3000 à 6000 euros**.
- **Distribution** : L'histogramme suggère que les articles sont principalement concentrés dans la gamme de prix inférieure, ce qui pourrait indiquer que les articles plus abordables sont plus courants ou plus populaires.




- **Concentration des Poids** : La majorité des données se situent entre 2,0 et 2,5 sur l'axe des x, ce qui indique que c'est la plage de poids la plus commune.
- **Diminution avec le Poids** : Il y a une diminution significative du nombre d'occurrences au-delà d'une valeur de poids de 3,0.
- **Distribution** : La distribution a une forme irrégulière avec un pic le plus élevé entre 2,0 et 2,5, ce qui pourrait indiquer une concentration de valeurs dans cette plage.

*Affiche les statistiques descriptives de la colonne 'Ram' pour chaque entreprise



	Ram count	mean	std	min	25%	50%	75%	max
Company								
Acer	48.0	6.583333	2.640385	4.0	4.0	8.0	8.0	16.0
Apple	10.0	10.400000	3.864367	8.0	8.0	8.0	14.0	16.0
Asus	43.0	9.581395	5.581571	4.0	8.0	8.0	8.0	32.0
Dell	130.0	8.600000	3.973946	4.0	8.0	8.0	8.0	32.0
Fujitsu	2.0	8.000000	0.000000	8.0	8.0	8.0	8.0	8.0
Google	2.0	12.000000	5.656854	8.0	10.0	12.0	14.0	16.0
HP	102.0	7.372549	2.883622	4.0	4.0	8.0	8.0	16.0
Huawei	2.0	8.000000	0.000000	8.0	8.0	8.0	8.0	8.0
LG	1.0	8.000000	NaN	8.0	8.0	8.0	8.0	8.0
Lenovo	126.0	8.079365	3.798111	4.0	4.0	8.0	8.0	24.0
MSI	3.0	8.000000	0.000000	8.0	8.0	8.0	8.0	8.0
Microsoft	5.0	8.800000	4.381780	4.0	8.0	8.0	8.0	16.0
Razer	2.0	24.000000	11.313708	16.0	20.0	24.0	28.0	32.0
Toshiba	21.0	9.904762	6.402381	4.0	8.0	8.0	8.0	32.0
Xiaomi	3.0	10.666667	4.618802	8.0	8.0	8.0	12.0	16.0


Diagramme à barres pour représenter la distribution des entreprises dans le DataFrame



<Figure size 1000x600 with 0 Axes>

- **Dell en Tête** : Dell a la fréquence la plus élevée, dépassant **120**.
- **Lenovo et HP Suivent** : Lenovo et HP suivent avec des fréquences d'environ **100** et juste au-dessus de **80**, respectivement.

***comparer visuellement la distribution des prix des ordinateurs portables entre les sept entreprises les plus fréquentes dans le DataFrame.**




D'après la description de l'image, le graphique est un **boxplot** intitulé "Boxplot of Price_euros by Top 7 Companies":

- **Acer** : Montre la médiane la plus basse des prix, indiquant que les produits Acer ont tendance à être les moins chers parmi les sept entreprises.
- **Apple** : Présente la médiane la plus élevée, ce qui suggère que les produits Apple sont généralement plus chers.
- **Asus, Dell, HP, Lenovo, Toshiba** : Ont des médianes de prix intermédiaires, avec des distributions de prix variées.

IV)ACP:

- **matrice de corrélation :**



```
laptop_ID    Inches  Ram  Weight  Price_euros  ScreenResolution  powerCpu  \
1            13.3    8    1.37    1339.69         4096000      416875.0
3            15.6    8    1.86     575.00         2073600      450000.0
4            15.4   16    1.83    2537.45         5184000      959175.0
5            13.3    8    1.37    1803.60         4096000      561875.0
9            14.0   16    1.30    1495.00         2073600      754110.0
...          ...    ...    ...         ...         ...         ...
743          15.6    4    1.85     779.00         2073600      992250.0
744          15.6   16    2.60    2419.00         2073600     1056440.0
745          13.3    8    1.55     659.00         2073600      330000.0
747          15.6    4    2.40     410.80         1049088      108108.0
749          15.6    8    2.00     665.00         1049088      108108.0

Memory_size
laptop_ID
1            128
3            256
4            512
5            256
9            512
...          ...
743          1024
744            256
745          1024
747            500
749            256

[500 rows x 7 columns]
```

	Inches	Ram	Weight	Price_euros	ScreenResolution	powerCpu	Memory_size
Inches	1.000000	-0.064698	0.867201	-0.208620	-0.221141	-0.034520	0.344026
Ram	-0.064698	1.000000	-0.017116	0.724171	0.411646	0.554049	0.023940
Weight	0.867201	-0.017116	1.000000	-0.163809	-0.230377	0.001507	0.330086
Price_euros	-0.208620	0.724171	-0.163809	1.000000	0.569342	0.621511	-0.159825
ScreenResolution	-0.221141	0.411646	-0.230377	0.569342	1.000000	0.301030	-0.064113
powerCpu	-0.034520	0.554049	0.001507	0.621511	0.301030	1.000000	-0.042536
Memory_size	0.344026	0.023940	0.330086	-0.159825	-0.064113	-0.042536	1.000000

→Ce matrice de corrélation présente des variables fortement corrélées par exemples :
(Inches,Weight),(ram,price_euros),(powercpu, price_euros), (screenResplution,price_euros)

La variable Memory_size est presque non corrélée avec aucune autre variable.

Les valeurs propres :


```
[2.79507638 1.95319814 0.82828537 0.64858822 0.13004352 0.43104829
 0.21376008]
```


Les vecteurs propres :

```

[[ 0.30659675 -0.5544683  0.19966751  0.24388333  0.70574166 -
0.02731503
  0.01999353]
[-0.43925015 -0.32095838 -0.02331078 -0.17682289  0.0182591
0.66160096
  0.48392775]
[ 0.28510648 -0.57084844  0.23656444  0.19423649 -0.70355834
0.03269612
 -0.05560955]
[-0.52268782 -0.20315243  0.07550355  0.04117477  0.06075961
0.15614984
 -0.80626043]
[-0.41351715 -0.0658247  -0.34363459  0.7541667  -0.05306792 -
0.28509408
  0.23178374]
[-0.39571822 -0.30484236  0.23129984 -0.45421448 -0.00773251 -
0.67088483
  0.20129968]
[ 0.17601171 -0.35376548 -0.85225679 -0.30782009 -0.00576566 -
0.06871065
 -0.13424095]]


```






Les trois premières valeurs propres expliquent 82% de l'inertie totale, donc nous allons utiliser les trois premiers axes factoriels.

****Les projections des individus sur les deux premiers plans factoriels.**





Les individus situés autour des extrémités du plan factoriel sont bien représentés. Ceux proches de l'origine sont soit mal représentés, soit bien représentés, auquel cas ils auraient des valeurs moyennes au niveau des différentes variables.

-Pour l'individu 200, il est bien représenté sur le premier plan factoriel, donc sur le premier et le deuxième axe, mais il est mal représenté sur le troisième axe.

*ACP du nuage des points variables :

```
# Calcul des contributions des individus dans l'inertie sur Axe1, Axe2
et Axe3
# Calcul de la qualité de représentation des individus sur Axe1, Axe2
et Axe3
```


	ID	Contr_1	Contr_2	Contr_3	Coscar_1	Coscar_2	Coscar_3
0	1	0.166807	0.332232	0.012262	34.195348	47.593442	0.744909
1	3	0.028639	0.015600	0.073115	24.997994	9.515327	18.912352
2	4	0.832846	0.269771	0.028361	74.900578	16.953850	0.755838
3	5	0.295503	0.198446	0.031214	57.769278	27.110013	1.808273
4	9	0.275269	0.009539	0.018963	58.217021	1.409811	1.188461
..	...	...	...	...	...	...	...
495	743	0.024533	0.036032	0.147995	6.630210	6.804939	11.852724
496	744	0.312300	0.511096	0.546824	34.417853	39.361081	17.858538
497	745	0.006996	0.135604	0.792456	1.762955	23.880251	59.179970
498	747	0.396300	0.008427	0.017606	90.634756	1.346775	1.193208
499	749	0.135090	0.033869	0.102461	46.846951	8.207587	10.529388

```
# Calcul des contributions des variables dans l'inertie sur Axe1, Axe2
et Axe3
# Calcul de la qualité de représentation des variables sur Axe1, Axe2
et Axe3
```


	ID	corvar1	corvar2	corvar3	Ctrvar1	Ctrvar2	\
0	Inches	-0.513097	0.775684	-0.181900	9.400157	30.743509	
1	Ram	0.735095	0.449011	0.021236	19.294070	10.301428	
2	Weight	-0.477132	0.798599	-0.215513	8.128571	32.586795	
3	Price_euros	0.874730	0.284204	-0.068785	27.320256	4.127091	
4	ScreenResolution	0.692030	0.092087	0.313056	17.099643	0.433289	
5	powerCpu	0.662243	0.426465	-0.210717	15.659291	9.292886	
6	Memory_size	-0.294560	0.494907	0.776417	3.098012	12.515002	

	Ctrvar3	Cosvar1	Cosvar2	Cosvar3
0	3.986712	26.326810	60.168502	3.308752
1	0.054339	54.036472	20.161053	0.045099
2	5.596273	22.765507	63.776018	4.644600
3	0.570079	76.515233	8.077181	0.473134
4	11.808473	47.890589	0.847995	9.800386
5	5.349962	43.856628	18.187223	4.440175
6	72.634163	8.676534	24.493264	60.282379

```
# Positionnement des individus dans le premier plan
```



Cercle des corrélations pour les variables projetées sur Axe1 et Axe2




Les variables bien représentées sont celles qui sont proches du cercle, celles qui sont proches de l'origine sont mal représentées.

Les variables screenresolution , price , ram et power_cpu sont fortement corrélées positivement avec l'axe 1


Les variables weight et Inches sont fortement corrélées positivement avec l'axe 2

Memory_size n'est pas corrélé ni avec l'axe 1 ni avec l'axe 2

```
# Positionnement des individus dans le plan défini par Axe2 et Axe3
```



```
# Cercle des corrélations pour les variables projetées sur Axe2 et Axe3
```



Memory_size est fortement corrélé avec l'axe 3

****Interprétation des axes factoriels :**

Axe 1 :

Variables bien représentées : screenresolution, price, ram et power_cpu.

Interprétation : Cet axe semble être lié aux caractéristiques de performance et de qualité de l'écran, ainsi qu'au prix et à la puissance du processeur. Les valeurs élevées sur cet axe indiquent probablement des ordinateurs portables haut de gamme avec des écrans de haute résolution, une puissance de traitement élevée et un prix plus élevé.

Axe 2 :

Variables bien représentées : weight et inches.

Interprétation : Cet axe semble être associé à la portabilité et à la taille de l'ordinateur portable. Les valeurs élevées sur cet axe indiquent probablement des ordinateurs portables plus lourds et de plus grande taille.

Axe 3 :

Variable bien représentée : Memory_size.

Interprétation : Cet axe semble être lié à la capacité de stockage de l'ordinateur portable. Les valeurs élevées sur cet axe pourraient indiquer des ordinateurs portables avec une plus grande capacité de stockage.

-> l'axe 1 représente les caractéristiques de performance et de prix, l'axe 2 représente la portabilité et la taille, tandis que l'axe 3 représente la capacité de stockage des ordinateurs portables.

V) Analyse factorielle des correspondances (AFC) :

Le tableau de contingence suivant indique la répartition, en fonction de Company (Hp, Asus,Dell,Lenovo) et de price_category (Expensive,Normal,Low) des 500 ordinateurs :

Transformations sur le prix pour le rendre qualitatives :

- Sélection des entreprises :

Il compte le nombre d'occurrences de chaque entreprise dans le DataFrame, sélectionne les quatre entreprises les plus fréquentes et filtre le DataFrame pour ne conserver que les lignes correspondant à ces entreprises.

- Catégorisation des prix :

Il crée une nouvelle colonne 'Price_Category' en appliquant une fonction à la colonne 'Price_euros'. Cette fonction catégorise les prix en 'Low', 'Normal' et 'Expensive' en fonction de leur valeur

```
laptop_ID
3          HP      575.00
9          Asus    1495.00
11         HP      393.90
12         HP      344.99
14         Dell    498.90
...         ...      ...
636        Dell    1820.00
637        Asus    1900.00
639        Dell    1479.00
640        Lenovo   829.00
641        Lenovo   579.00

[500 rows x 2 columns]
Company Price_Category
laptop_ID
3          HP          Low
9          Asus       Normal
11         HP          Low
12         HP          Low
14         Dell       Low
...         ...      ...
636        Dell       Normal
637        Asus       Normal
639        Dell       Normal
640        Lenovo     Low
641        Lenovo     Low
[500 rows x 2 columns]
```

****Le tableau de contingence en effectif**

Company	HP	Asus	Dell	Lenovo
Price_Category				
Expensive	2	5	15	14
Low	72	43	77	91
Normal	44	40	57	40

***Etude de dépendances entre les deux variables :**

```
Statistique du chi carré : 16.37679917166455
Valeur de p : 0.011868253451999992
On rejette H0 et on accepte H1, les deux variables sont dépendantes
```

Affichage de la matrice de fréquences

Matrice de fréquences F :

Company	HP	Asus	Dell	Lenovo
Price_Category				
Expensive	0.004	0.010	0.030	0.028
Low	0.144	0.086	0.154	0.182
Normal	0.088	0.080	0.114	0.080

Affichage des vecteurs de poids des lignes et des colonnes

Vecteur de poids des lignes (distribution marginale des lignes) :

```
Price_Category
Expensive    0.072
Low          0.566
Normal       0.362
```

dtype: float64

Vecteur de poids des colonnes (distribution marginale des colonnes) :

```
Company
HP      0.236
Asus    0.176
Dell    0.298
Lenovo  0.290
```

dtype: float64

```
# Affichage de la matrice des profils de lignes
```

Matrice des profils de lignes (distribution conditionnelle en ligne) :





Company	HP	Asus	Dell	Lenovo
Price_Category				
Expensive	0.055556	0.138889	0.416667	0.388889
Low	0.254417	0.151943	0.272085	0.321555
Normal	0.243094	0.220994	0.314917	0.220994

```
# Affichage de la matrice des profils de colonnes
```

Matrice des profils de colonnes (distribution conditionnelle en colonne) :




Company	HP	Asus	Dell	Lenovo
Price_Category				
Expensive	0.016949	0.056818	0.100671	0.096552
Low	0.610169	0.488636	0.516779	0.627586
Normal	0.372881	0.454545	0.382550	0.275862

***Traçage de chaque profil ligne**



- **HP** : La catégorie "Cher" a une très faible fréquence, tandis que les catégories "Bas" et "Normal" ont une fréquence élevée, avec "Normal" légèrement plus élevée.
- **Asus** : Toutes les trois catégories de prix ont des fréquences notables, avec "Normal" étant la plus élevée suivie de "Bas", puis "Cher" qui est significativement plus basse.
- **Dell** : Les fréquences sont réparties plus uniformément entre toutes les trois catégories, avec "Normal" menant légèrement.
- **Lenovo** : Les catégories "Cher" et "Bas" ont des fréquences similaires et élevées, tandis que "Normal" est significativement plus basse.


***Traçage de chaque profil colonne :**



- **Catégorie 'Cher'** : Lenovo domine cette catégorie, suivie de près par Dell. Asus et HP ont des fréquences plus basses.
- **Catégorie 'Bas'** : Toutes les marques présentent des fréquences élevées et similaires, indiquant une forte présence dans le segment de prix bas.
- **Catégorie 'Normal'** : Dell a la fréquence la plus élevée, indiquant que la plupart de ses ordinateurs portables sont dans une gamme de prix moyenne. Lenovo suit, tandis que HP et Asus ont des fréquences plus basses.

K-Means Clustering :


```
# Plot the scatter matrix
```



Interprétation:

- **Inches et Weight** : Il y a une forte corrélation positive entre la taille de l'écran (Inches) et le poids (Weight). Cela signifie que les ordinateurs portables avec des écrans plus grands ont tendance à être plus lourds.
- **Ram et Price_euros** : Il y a une corrélation positive significative entre la mémoire RAM et le prix en euros. Cela suggère que les ordinateurs portables avec plus de RAM ont tendance à être plus chers.
- **Ram et powerCpu** : Il y a une corrélation positive modérée entre la mémoire RAM et la puissance du CPU. Cela pourrait indiquer que les ordinateurs portables avec plus de RAM ont tendance à avoir des CPU plus puissants.
- **Price_euros et powerCpu** : Il y a une corrélation positive significative entre le prix en euros et la puissance du CPU. Cela suggère que les ordinateurs portables avec des CPU plus puissants ont tendance à être plus chers.

Visualisation des résultats de la classification en 4 clusters avec PCA :



Interprétation des clusters pour déterminer se qui représenter chaque cluster :

Cluster Vert : Principalement dans la région négative du premier axe principal et la région positive du deuxième axe principal. Ces ordinateurs portables pourraient avoir des performances et une qualité d'écran inférieures, mais sont plus portables et de taille plus petite.


Cluster Bleu : Réparti autour de l'origine, ce qui indique un mélange équilibré de toutes les caractéristiques. Ces ordinateurs pourraient représenter la gamme moyenne offrant un compromis entre performance, prix et portabilité.

Cluster Violet : S'étend vers les valeurs positives sur les deux axes. Cela suggère des ordinateurs portables avec de bonnes performances et une qualité d'écran, mais qui sont également plus grands et potentiellement plus lourds.

Cluster Jaune : Positionné dans la région positive du premier axe principal et autour de zéro sur le deuxième axe principal. Ces ordinateurs pourraient être des modèles haut de gamme avec une excellente qualité d'écran et de bonnes performances, mais de taille et poids variés.

Interprétation des clusters en tenant compte de la taille et de la dispersion :

- **Cluster Vert** : Ce cluster pourrait représenter des ordinateurs portables avec des caractéristiques de performance inférieures mais une meilleure portabilité et une taille plus petite. La dispersion des points dans ce cluster est relativement faible, ce qui indique que les ordinateurs portables dans ce groupe sont très similaires les uns aux autres.
- **Cluster Bleu** : Ce cluster semble indiquer des ordinateurs portables offrant un équilibre entre les caractéristiques de performance, de prix et de portabilité. La dispersion des points dans ce cluster est plus grande, ce qui indique une plus grande variété d'ordinateurs portables.
- **Cluster Violet** : Ce cluster suggère des ordinateurs portables avec de bonnes performances et une qualité d'écran supérieure, mais qui sont également plus grands et plus lourds. La dispersion des points dans ce cluster est moyenne, ce qui indique une certaine variété d'ordinateurs portables.
- **Cluster Jaune** : Ce cluster pourrait inclure des ordinateurs portables haut de gamme avec une excellente qualité d'écran et de bonnes performances. La dispersion des points dans ce cluster est moyenne à élevée, ce qui indique une variété d'ordinateurs portables haut de gamme.



L'analyse de la méthode du coude indique que le choix optimal du nombre de clusters pour l'analyse K-Means est de 3.

Extraire des informations des cluster l'analyse K-Means est de 3 :

Moyennes des caractéristiques de chaque cluster :

	Inches	Ram	Weight	Price_euros	ScreenResolution	\
cluster						
0	14.940278	15.111111	1.901528	2167.890694	3.683925e+06	
1	15.817091	6.792727	2.236036	756.405927	1.777177e+06	
2	13.607843	7.738562	1.459320	1185.750131	2.373542e+06	

	powerCpu	Memory_size
cluster		
0	4.179441e+06	487.111111
1	1.776494e+06	638.807273
2	2.041310e+06	312.418301

Différences significatives entre les clusters :

	Inches	Ram	Weight	Price_euros	ScreenResolution	\
cluster						
1	0.876813	-8.318384	0.334509	-1411.484767	-1.906748e+06	
2	-2.209248	0.945835	-0.776716	429.344203	5.963645e+05	

	powerCpu	Memory_size
cluster		
1	-2.402947e+06	151.696162
2	2.648164e+05	-326.388972

Caractéristiques les plus discriminantes pour chaque cluster :

Cluster 1:

Caractéristique la plus discriminante: Memory_size, Différence: 151.6961616161616

Cluster 2:


Caractéristique la plus discriminante: ScreenResolution, Différence: 596364.5125133691

Interprétation des clusters obtenus par l'algorithme K-means :

- **Cluster 0** : Modèles haut de gamme avec d'excellentes performances.
- **Cluster 1** : Modèles de milieu de gamme offrant un bon équilibre entre performance et prix.
- **Cluster 2** : Modèles d'entrée de gamme avec une grande capacité de stockage.

La caractéristique la plus discriminante pour chaque cluster est celle qui présente la plus grande différence par rapport à la moyenne des autres clusters. Pour le cluster 1, c'est la taille de la mémoire, et pour le cluster 2, c'est la résolution de l'écran. Ces caractéristiques sont les plus significatives pour distinguer chaque cluster des autres.

Visualisation des résultats de la classification en 3 clusters avec PCA :



Interprétation des clusters pour déterminer se qui représenter chaque cluster :

- **Cluster Teal** : Situé principalement dans la région négative du premier axe principal et la région positive du deuxième axe principal. Ces ordinateurs portables pourraient être plus légers et de taille plus petite, indiquant une meilleure portabilité.
- **Cluster Jaune** : Réparti autour de l'origine, ce qui pourrait indiquer une gamme variée d'ordinateurs portables avec un équilibre entre les caractéristiques de performance, de prix et de portabilité.
- **Cluster Violet** : S'étend vers les valeurs positives sur les deux axes, ce qui suggère des ordinateurs portables avec de bonnes performances et une qualité d'écran supérieure, mais qui sont également plus grands et plus lourds.

Interprétation des clusters en tenant compte de la taille et de la dispersion :

- **Cluster Teal** : Ce cluster a une grande dispersion et une densité relativement faible. Cela pourrait indiquer une variété d'ordinateurs portables avec des caractéristiques similaires mais distinctes en termes de portabilité.
- **Cluster Jaune** : Il est plus concentré autour de l'origine, ce qui indique que les ordinateurs portables dans ce cluster sont assez uniformes en termes d'équilibre entre performance, prix et portabilité.

- **Cluster Violet :** Bien que moins dispersé que le cluster teal, il s'étend davantage sur l'axe positif, montrant une diversité dans les performances et la qualité d'écran mais avec une tendance vers des spécifications supérieures.